# **Azkaban**

# 第一章 Azkaban概论

### 为什么需要工作流调度系统

- 1) 一个完整的数据分析系统通常都是由大量任务单元组成: Shell 脚本程序、Java程序、MapReduce程序、Hive脚本等。
- 2) 各任务单元之间存在 时间先后及前后依赖关系。
- 3) 为了很好地组织起这样的复杂执行计划,需要一个工作流调度系统来调度执行;

### 常见工作流调度系统

- 1) 简单的任务调度: 直接使用Linux的Crontab来定义;
- 2)复杂的任务调度:开发调度平台或使用现成的开源调度系统,比如 Ooize、Azkaban、Airflow、DolphinScheduler等。

# 第二章 WorkFlow案例

## 1 HelloWorld案例

1) 在windows环境,新建azkaban.project文件,编辑内容如下


```
1 azkaban-flow-version: 2.0
```

注意:该文件作用,是采用新的Flow-API方式解析flow文件。


2) 新建basic.flow文件,内容如下

```
nodes:
nodes:
nodes:
nodes:
type: command
config:
command: echo "Hello World"
```


- 3) 将 azkaban. project 、 basic. flow 文件压缩到一个 zip 文件, 文件名称 必须是英文。
- 4) 在WebServer 新建项目: http://master:8081/index



5) 给项目名称命名和添加项目描述




6) first.zip文件上传



### 7) 选择上传的文件




### 8) 执行任务流








### 9) 在日志中, 查看运行结果





## 2 作业依赖案例


需求: JobA和JobB执行完了,才能执行JobC


#### 具体步骤:


1) 修改basic.flow为如下内容


```
nodes:
2
       - name: jobC
         type: command
          # jobC 依赖 JobA和JobB
4
         dependsOn:
6
            - jobA
             - jobB
8
        config:
            command: echo "I' m JobC"
9
       - name: jobA
12
          type: command
         config:
14
             command: echo "I' m JobA"
16
       - name: jobB
          type: command
18
          config:
19
             command: echo "I' m JobB"
```

- 2) 将修改后的basic.flow和azkaban.project压缩成second.zip文件
- 3) 重复HelloWorld案例后续步骤。









### 3 自动失败重试案例


需求:如果执行任务失败,需要重试3次,重试的时间间隔10000ms

#### 具体步骤:

1) 编译配置流

```
nodes:
node
```

- 2) 将修改后的basic.flow和azkaban.project压缩成four.zip文件
- 3) 重复HelloWorld案例后续步骤。
- 4) 执行并观察到一次失败+三次重试



5) 也可以点击上图中的Log, 在任务日志中看到, 总共执行了4次。



## 4 手动失败重试案例


需求: JobA -> JobB (依赖于A) -> JobC -> JobD -> JobE -> JobF。生产环境下任何Job都有可能挂掉,可以根据需求执行想要执行的Job。

### 具体步骤:


1) 编译配置流

```
nodes:
 2
       - name: JobA
          type: command
 4
           config:
             command: echo "This is JobA."
 6
 7
       - name: JobB
 8
          type: command
9
           dependsOn:
             - JobA
           config:
             command: echo "This is JobB."
       - name: JobC
14
          type: command
16
           dependsOn:
             - JobB
18
           config:
             command: echo "This is JobC."
19
21
        - name: JobD
           type: command
           dependsOn:
             - JobC
24
25
           config:
             command: echo "This is JobD."
26
27
       - name: JobE
28
29
          type: command
30
           dependsOn:
             - JobD
32
          config:
             command: echo "This is JobE."
34
        - name: JobF
36
           type: command
           dependsOn:
38
             - JobE
39
           config:
40
             command: echo "This is JobF."
```

- 2) 将修改后的basic.flow和azkaban.project压缩成five.zip文件
- 3) 重复HelloWorld案例后续步骤。







Enable和Disable下面都分别有如下参数:

Parents: 该作业的上一个任务

Ancestors: 该作业前的所有任务

Children: 该作业后的一个任务

Descendents: 该作业后的所有任务

Enable All: 所有的任务

4) 可以根据需求选择性执行对应的任务。

# 第三章 Azkaban进阶

## JavaProcess作业类型案例

JavaProcess类型可以运行一个自定义主类方法, type类型为javaprocess, 可用的配置为:

Xms: 最小堆

Xmx: 最大堆

classpath: 类路径

java.class:要运行的 Java 对象,其中必须包含Main方法

main.args: main 方法的参数

案例:

1) 新建一个azkaban的maven工程

2) 创建包名: com.atguigu

3) 创建AzTest类

```
package com.atguigu;

public class AzTest {
    public static void main(String[] args) {
        System.out.println("This is for testing!");
    }
}
```

- 4) 打包成jar包azkaban-1.0-SNAPSHOT.jar
- 5) 新建testJava.flow,内容如下

```
nodes:

- name: test_java

type: javaprocess

config:

Xms: 96M


Xmx: 200M


java.class: com.atguigu.AzTest
```

- 6) 将Jar包、flow文件和project文件打包成javatest.zip
- 7) 创建项目 -> 上传javatest.zip -> 执行作业 -> 观察结果









### 条件工作流案例

条件工作流功能允许用户 自定义执行条件 来决定是否运行某些Job。条件可以由当前Job 的父Job输出的运行时参数构成,也可以使用预定义宏。在这些条件下,用户可以在确定Job 执行逻辑时获得更大的灵活性,例如,只要父Job之一成功,就可以运行当前Job。

### 运行时参数案例

- 1) 基本原理
- (1) 父Job将参数写入JOB\_OUTPUT\_PROP\_FILE环境变量所指向的文件
- (2) 子Job使用\${jobName:param}来获取父Job输出的参数并定义执行条件
- 2) 支持的条件运算符:
- (1) == 等于
- (2) != 不等于
- (3) > 大于
- (4) >= 大于等于
- (5) < 小于
- (6) <= 小于等于
- (7) &&与
- (8) ||或
- (9)!非
- 3) 案例:

需求: JobA 执行一个shell脚本。JobB 执行一个shell脚本,但JobB不需要每天都执行,而只需要每个周一执行。

(1) 新建JobA.sh

```
1 #!/bin/bash
2 echo "do JobA"
3 wk=`date +%w`
4 echo "{\"wk\":$wk}" > $JOB_OUTPUT_PROP_FILE
```

(2) 新建JobB.sh

```
1 #!/bin/bash
2 echo "do JobB"
```

(3) 新建condition.flow

```
nodes:
  - name: JobA
2
       type: command
4
       config:
          command: sh JobA.sh
6
     - name: JobB
7
        type: command
        dependsOn: - JobA
8
9
       config:
          command: sh JobB.sh
          condition: ${JobA:wk} == 1
```

- (4) 将JobA.sh、JobB.sh、condition.flow 和 azkaban.project 打包成 condition.zip
- (5) 创建condition 项目 -> 上传condition.zip 文件 -> 执行作业 -> 观察结果
- (6) 按照我们设定的条件, JobB会根据当日日期决定是否执行。

### 预定义宏案例

Azkaban中预置了几个特殊的判断条件,称为 预定义宏。 预定义宏会根据所有父Job的完成情况进行判断,再决定是否执行。可用的预定义宏如下:

- (1) all\_success: 表示父 Job 全部成功才执行(默认)
- (2) all\_done: 表示父Job全部完成才执行
- (3) all\_failed:表示父 Job 全部失败才执行
- (4) one\_success: 表示父Job至少一个成功才执行
- (5) one\_failed:表示父Job 至少一个失败才执行
- 1) 案例

需求: JobA 执行一个shell脚本, JobB 执行一个shell脚本, JobC执行一个shell脚本, 要求JobA、JobB中有一个成功即可执行

(1) 新建JobA.sh

```
1 #!/bin/bash
2 echo "do JobA"
```

(2) 新建JobC.sh

```
1 #!/bin/bash
2 echo "do JobC"
```

(3) 新建macro.flow

```
nodes:
 2
      - name: JobA
 3
         type: command
 4
         config:
            command: sh JobA.sh
       - name: JobB
         type: command
          config:
 8
 9
             command: sh JobB.sh
       - name: JobC
          type: command
          dependsOn: - JobA
                           - JobB
         config:
14
            command: sh JobC.sh
            condition: one_success
16
```


- (4) JobA.sh、JobC.sh、macro.flow、azkaban.project 文件, 打包成 macro.zip。注意: 没有JobB.sh。
- (5) 创建macro项目 -> 上传macro.zip文件 -> 执行作业 -> 观察结果

## 定时执行案例


需求: JobA每间隔1分钟执行一次;


#### 具体步骤:

1) Azkaban 可以定时执行工作流。在执行工作流时候,选择左下角Schedule。





2) 右上角注意时区是上海,然后在左面填写具体执行事件,填写的方法和crontab配置定时任务规则一致。






#### 3) 观察结果





### 4) 删除定时调度

点击remove Schedule即可删除当前任务的调度规则。



## 多Executor模式注意事项


Azkaban多Executor模式是指,在集群中多个节点部署Executor。在这种模式下,Azkaban web Server会根据策略,选取其中一个Executor去执行任务。为确保所选的Executor能够准确的执行任务,我们须在以下两种方案任选其一,推荐使用方案二。

方案一: 指定特定的Executor (hadoop102) 去执行任务。

1) 在MySQL中azkaban数据库executors表中,查询hadoop102上的Executor的id。

```
use azkaban;
select * from executors;
```

2) 在执行工作流程时加入useExecutor属性,如下



方案二:在Executor所在所有节点部署任务所需脚本和应用。